РК №1.

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему
https://www.kaggle.com/mohansacharya/graduate-admissions
(файл Admission_Predict_Ver1.1.csv)

Текстовое описание набора данных

В качестве набора данных мы будем использовать набор данных по предсказанию поступления в аспирантуру

Данные доступны по ссылке https://www.kaggle.com/datasets/mohansacharya/graduate-admissions Эта задача является актуальной для людей, собирающихся поступать в аспирантуру, и которым необходимо оценить свои шансы.

Датасет состоит из 1 файла:

- Admission_Predict.csv

Файл содержит следующие колонки:

- GRE Score - баллы за экзамен GRE для поступления в магистратуру/аспирантуру.
- TOEFL Score - баллы за экзамен TOEFL по английскому.
- University Rating - рейтинг университета.
- SOP - мотивация соискателя
- LOR - сила рекомендательного письма.
- CGPA - средний балл аттестата.
- Research - наличие опыта в исследовательских работах.
- Chance of Admit - шанс приема.
- University - название университета

Добавляем библиотеки

```
%pip install -q seaborn
%pip install -q scipy

import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
```

```
sns.set(style="ticks")

from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator

from sklearn.preprocessing import LabelEncoder

from sklearn.preprocessing import MinMaxScaler, StandardScaler,
Normalizer
```

Первичный анализ

```
data = pd.read_csv('Admission_Predict_Ver1.1.csv')

data.head()
```

```
   Serial No.  GRE Score  TOEFL Score  University Rating  SOP  LOR
CGPA  \
0           1        337          118                  4  4.5   4.5
9.65
1           2        324          107                  4  4.0   4.5
8.87
2           3        316          104                  3  3.0   3.5
8.00
3           4        322          110                  3  3.5   2.5
8.67
4           5        314          103                  2  2.0   3.0
8.21

   Research  Chance of Admit
0         1              0.92
1         1              0.76
2         1              0.72
3         1              0.80
4         0              0.65
```

```
data.shape
```

```
(500, 9)
```

```
data.keys()
```

```
Index(['Serial No.', 'GRE Score', 'TOEFL Score', 'University Rating',
'SOP',
       'LOR ', 'CGPA', 'Research', 'Chance of Admit '],
      dtype='object')
```

Обработка пустых значений для числового признака - импьютация (imputation)

```
# Проверим наличие пустых значений
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
```

```
Serial No. - 0
GRE Score - 0
TOEFL Score - 0
University Rating - 0
SOP - 0
LOR  - 0
CGPA - 0
Research - 0
Chance of Admit  - 0
```

```
# В имеющихся данных нет пропусков, создадим пропуски для числового
признака GRE Score
data.loc[:49, 'GRE Score'] = None

# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
total_count = data.shape[0]
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений
{}, {}%.'.format(col, dt, temp_null_count, temp_perc))
```

```
Колонка GRE Score. Тип данных float64. Количество пустых значений 50,
10.0%.
```

```
# Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

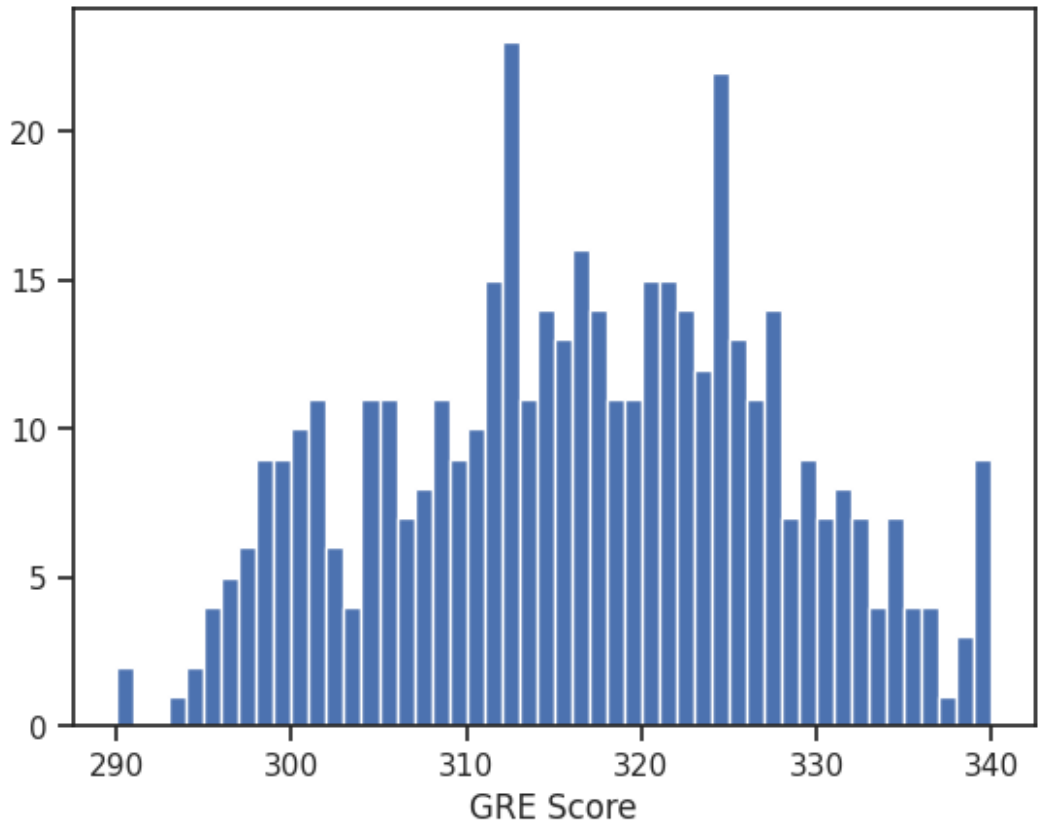


```
# Создание экземпляра SimpleImputer
imputer = SimpleImputer(strategy='median')

# Преобразование данных и заполнение пропущенных значений
data['GRE Score'] = imputer.fit_transform(data[['GRE Score']])

# Проверим наличие пустых значений
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
```

```
Serial No. - 0
GRE Score - 0
TOEFL Score - 0
University Rating - 0
SOP - 0
LOR  - 0
CGPA - 0
Research - 0
Chance of Admit  - 0
```

```
# Гистограмма по признакам
for col in data_num:
```

```
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

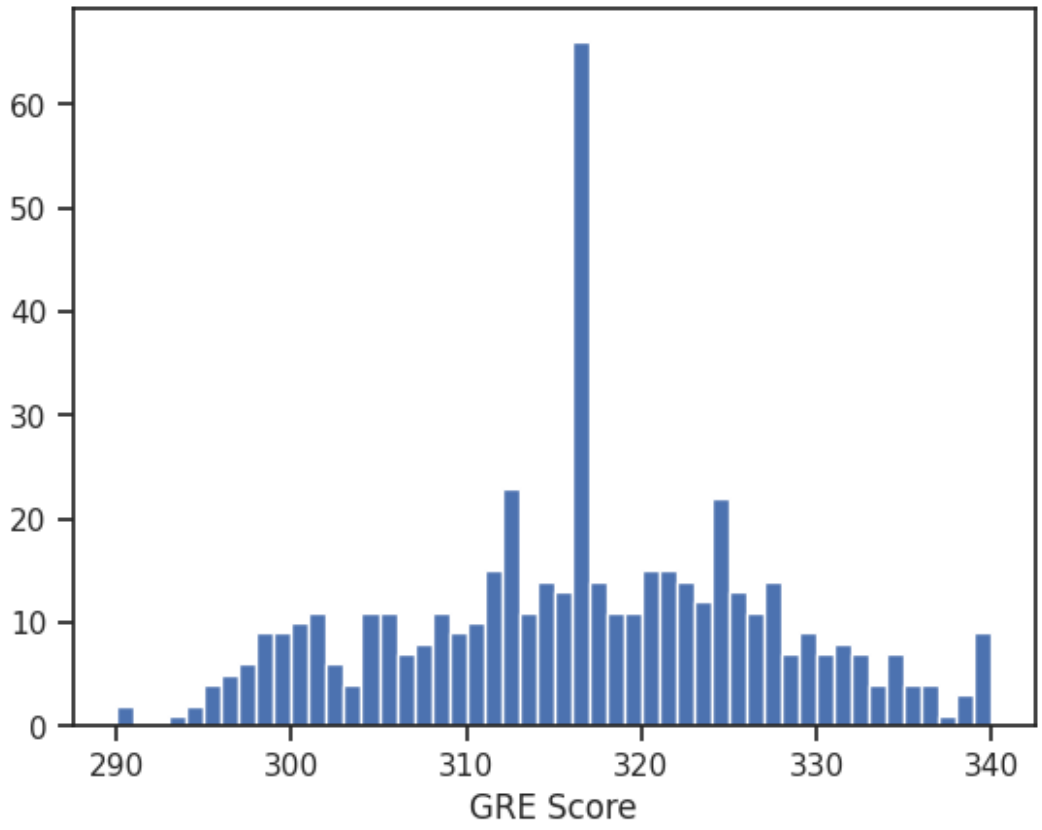

Кодирование категориальных признаков

Категориальные признаки отсутствую, поэтому создадим новую колоку Country - страну университета

Если баллы за TOEFL больше 115, то Англия.

Если баллы за TOEFL больше 107, но не более 115 то Фрнация.

В остальных случаях Индия.

```
type(data)
```

```
pandas.core.frame.DataFrame
```

```
def assign_country(score):
    if score > 115:
        return 'Great Britain'
```

```
    elif score > 107:
        return 'France'
    else:
        return 'India'

data['country'] = data['TOEFL Score'].apply(assign_country)

data.head()
```

```
   Serial No.  GRE Score  TOEFL Score  University Rating  SOP  LOR
CGPA  \
0           1      316.0          118                  4  4.5   4.5
9.65
1           2      316.0          107                  4  4.0   4.5
8.87
2           3      316.0          104                  3  3.0   3.5
8.00
3           4      316.0          110                  3  3.5   2.5
8.67
4           5      316.0          103                  2  2.0   3.0
8.21

   Research  Chance of Admit         country
0         1              0.92  Great Britain
1         1              0.76          India
2         1              0.72          India
3         1              0.80         France
4         0              0.65          India
```

Построение парных диаграмм

```
sns.pairplot(data)
```

```
<seaborn.axisgrid.PairGrid at 0xa8b6810>
```

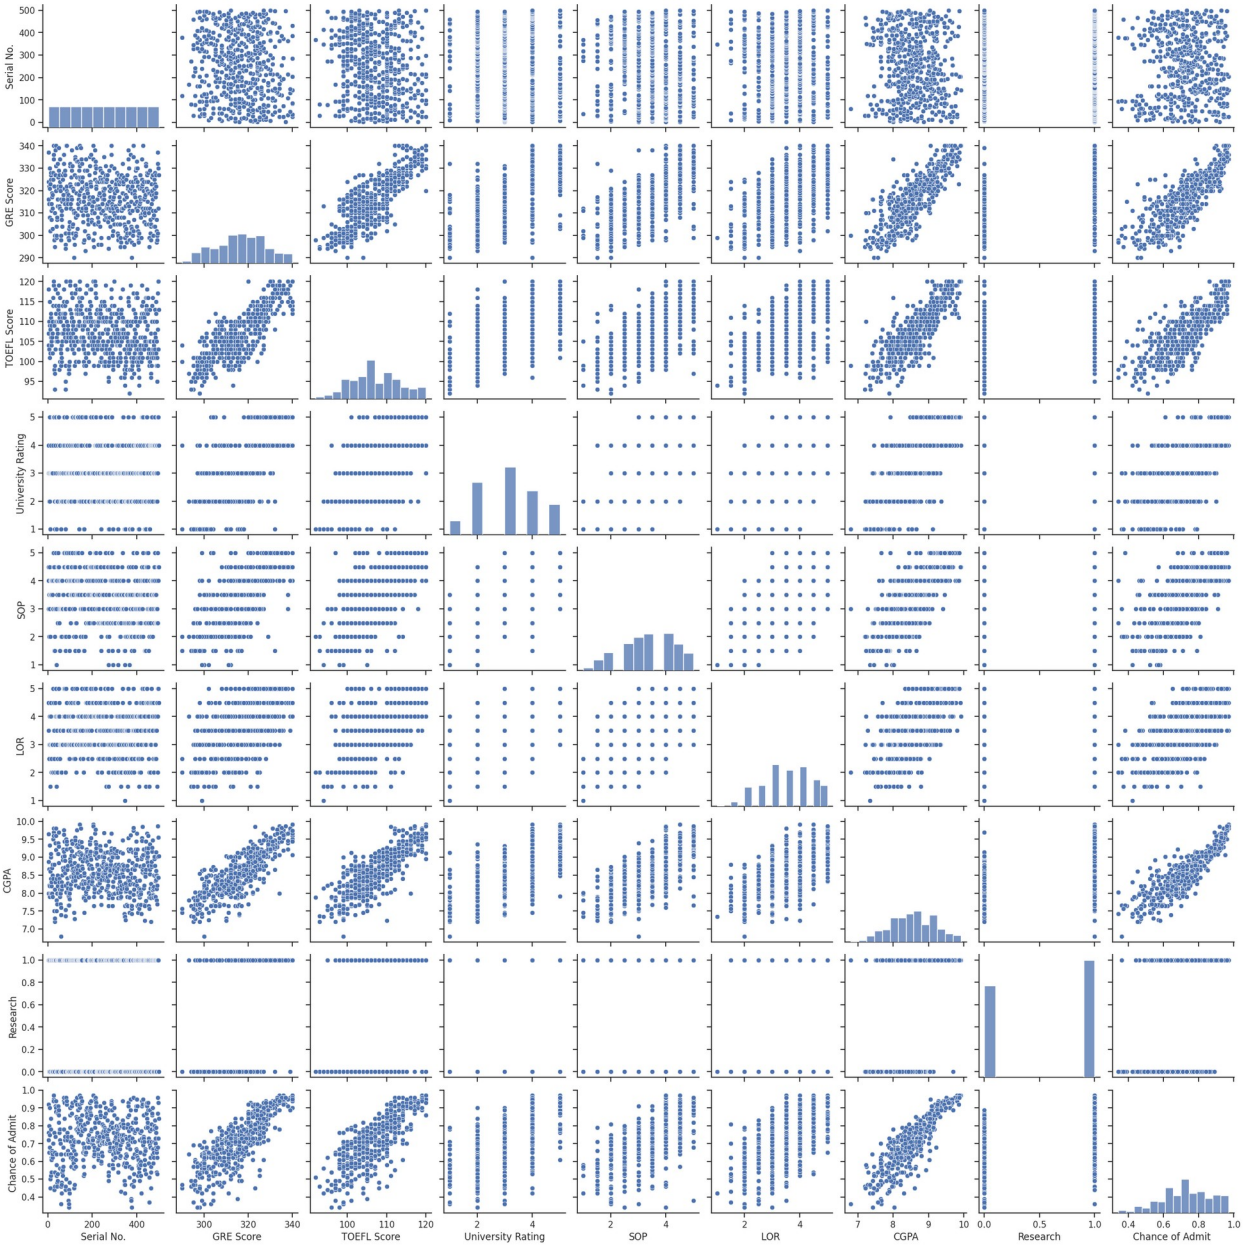
Serial No.
GRE Score
TOEFL Score
University Rating
SOP
LOR
CGPA
Research
Chance of Admit