

## РК №2

Задание. Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

ИУ5-65Б: Метод опорных векторов, Градиентный бустинг

<https://www.kaggle.com/fivethirtyeight/fivethirtyeight-comic-characters-dataset> (файл `marvel-wikia-data.csv`)

```
%pip install -q seaborn
%pip install -q xgboost

import numpy as np
import pandas as pd
from scipy import stats
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score,
classification_report
from sklearn.metrics import mean_absolute_error, mean_squared_error,
mean_squared_log_error, median_absolute_error, r2_score
from sklearn.preprocessing import MinMaxScaler
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR,
NuSVR, LinearSVR
from sklearn.model_selection import RandomizedSearchCV
from sklearn.ensemble import AdaBoostClassifier,
GradientBoostingClassifier
import seaborn as sns
import matplotlib.pyplot as plt
from xgboost import XGBClassifier
%matplotlib inline
sns.set(style="ticks")
```

```
data = pd.read_csv('marvel-wikia-data.csv')
```

```
data
```

	page_id	name \
0	1678	Spider-Man (Peter Parker)
1	7139	Captain America (Steven Rogers)
2	64786	Wolverine (James \"Logan\" Howlett)



2	Living Characters	3061.0	Oct-74	1974.0
3	Living Characters	2961.0	Mar-63	1963.0
4	Living Characters	2258.0	Nov-50	1950.0
...	...	...	...	...
16371	Living Characters	NaN	NaN	NaN
16372	Living Characters	NaN	NaN	NaN
16373	Living Characters	NaN	NaN	NaN
16374	Living Characters	NaN	NaN	NaN
16375	Living Characters	NaN	NaN	NaN

[16376 rows x 13 columns]

data.dtypes

```

page_id          int64
name             object
urlslug          object
ID               object
ALIGN            object
EYE              object
HAIR             object
SEX              object
GSM              object
ALIVE            object
APPEARANCES      float64
FIRST APPEARANCE object
Year             float64
dtype: object

```

## Обработка пустых значений

```

# Проверим наличие пустых значений
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))

page_id - 0
name - 0
urlslug - 0
ID - 3770
ALIGN - 2812
EYE - 9767
HAIR - 4264
SEX - 854
GSM - 16286
ALIVE - 3
APPEARANCES - 1096

```

```
FIRST APPEARANCE - 815
Year - 815
```

Удалим колонки в которых пропущено более проловины всех значений. Затем удалим строки с пропусками.

```
try:
    data = data.drop(['GSM', 'EYE'], axis=1)
    data = data.dropna(axis=0, how='any')
except:
    pass
data.shape

(8020, 11)
```

## Кодирование категориальных признаков

*#удалим признаки, не влияющие на целевой признак*

```
try:
    data = data.drop(['name', 'urlslug', 'FIRST APPEARANCE'], axis=1)
except:
    pass
data.head()
```

	page_id	ID	ALIGN	HAIR	SEX	ALIVE	APPEARANCES	Year
0	1678	1.000000	0.5	0.250000	1.0	1.0	4043.0	1962.0
1	7139	0.666667	0.5	0.958333	1.0	1.0	3360.0	1941.0
2	64786	0.666667	1.0	0.083333	1.0	1.0	3061.0	1974.0
3	1868	0.666667	0.5	0.083333	1.0	1.0	2961.0	1963.0
4	2460	0.333333	0.5	0.125000	1.0	1.0	2258.0	1950.0

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
le = LabelEncoder()
df_int = le.fit_transform(data['ID'])
data['ID'] = df_int
df_int = le.fit_transform(data['ALIGN'])
data['ALIGN'] = df_int
df_int = le.fit_transform(data['HAIR'])
data['HAIR'] = df_int
df_int = le.fit_transform(data['SEX'])
data['SEX'] = df_int
df_int = le.fit_transform(data['ALIVE'])
data['ALIVE'] = df_int
data.head()
```

	page_id	ID	ALIGN	HAIR	SEX	ALIVE	APPEARANCES	Year
0	1678	3	1	6	3	1	4043.0	1962.0
1	7139	2	1	23	3	1	3360.0	1941.0

2	64786	2	2	2	3	1	3061.0	1974.0
3	1868	2	1	2	3	1	2961.0	1963.0
4	2460	1	1	3	3	1	2258.0	1950.0

```

sc1 = MinMaxScaler()
data['ID'] = sc1.fit_transform(data[['ID']])
data['ALIGN'] = sc1.fit_transform(data[['ALIGN']])
data['HAIR'] = sc1.fit_transform(data[['HAIR']])
data['SEX'] = sc1.fit_transform(data[['SEX']])
data['ALIVE'] = sc1.fit_transform(data[['ALIVE']])
data.head()

```

	page_id	ID	ALIGN	HAIR	SEX	ALIVE	APPEARANCES	Year
0	1678	1.000000	0.5	0.250000	1.0	1.0	4043.0	1962.0
1	7139	0.666667	0.5	0.958333	1.0	1.0	3360.0	1941.0
2	64786	0.666667	1.0	0.083333	1.0	1.0	3061.0	1974.0
3	1868	0.666667	0.5	0.083333	1.0	1.0	2961.0	1963.0
4	2460	0.333333	0.5	0.125000	1.0	1.0	2258.0	1950.0

## Разделение на обучающую и тестовую выборки.

```

target = data['ALIVE']
data_X_train, data_X_test, data_y_train, data_y_test =
train_test_split(
    data, target, test_size=0.2, random_state=1)

data_X_train.shape, data_X_test.shape, data_y_train.shape,
data_y_test.shape

((6416, 8), (1604, 8), (6416,), (1604,))

```

## Метод опорных векторов

### Стандартная модель без доп параметров

```

svr_1 = LinearSVC(dual=False)
svr_1.fit(data_X_train, data_y_train)

LinearSVC(dual=False)

data_y_pred_1 = svr_1.predict(data_X_test)
accuracy_score(data_y_test, data_y_pred_1)

0.7356608478802993

```

```
f1_score(data_y_test, data_y_pred_1, average='micro')
0.7356608478802993
f1_score(data_y_test, data_y_pred_1, average='macro')
0.4238505747126437
f1_score(data_y_test, data_y_pred_1, average='weighted')
0.6236205463353112
```

Добавим параметр регуляризации (C), который контролирует штраф за неправильную классификацию обучающих образцов

```
svr_2 = LinearSVC(C=1.0, max_iter=10000, dual=False)
svr_2.fit(data_X_train, data_y_train)

LinearSVC(dual=False, max_iter=10000)

data_y_pred_2 = svr_2.predict(data_X_test)
accuracy_score(data_y_test, data_y_pred_2)
0.7356608478802993
f1_score(data_y_test, data_y_pred_2, average='micro')
0.7356608478802993
f1_score(data_y_test, data_y_pred_2, average='macro')
0.4238505747126437
f1_score(data_y_test, data_y_pred_2, average='weighted')
0.6236205463353112
```

## Градиентный бустинг

## Модель градиентного бустинга с использованием библиотеки xgboost

```
ab1 = XGBClassifier()
ab1.fit(data_X_train, data_y_train)

XGBClassifier(base_score=0.5, booster='gbtree', callbacks=None,
               colsample_bylevel=1, colsample_bynode=1,
               colsample_bytree=1,
```

```

        early_stopping_rounds=None, enable_categorical=False,
        eval_metric=None, gamma=0, gpu_id=-1,
grow_policy='depthwise',
        importance_type=None, interaction_constraints='',
        learning_rate=0.1, max_bin=256, max_cat_to_onehot=4,
        max_delta_step=0, max_depth=6, max_leaves=0,
min_child_weight=1,
        missing=nan, monotone_constraints='()',
n_estimators=100,
        n_jobs=0, num_parallel_tree=1, predictor='auto',
random_state=0,
        reg_alpha=0, reg_lambda=1, ...)

data_y_pred_1 = ab1.predict(data_X_test)
data_y_pred_1_0 = ab1.predict(data_X_train)
accuracy_score(data_y_train, data_y_pred_1_0)
1.0
accuracy_score(data_y_test, data_y_pred_1)
1.0
f1_score(data_y_test, data_y_pred_1, average='micro')
1.0
f1_score(data_y_test, data_y_pred_1, average='macro')
1.0
f1_score(data_y_test, data_y_pred_1, average='weighted')
1.0

```

Модель градиентного бустинга показала себя лучше, чем модель, основанная на методе опорных векторов